



Universidad Nacional de Ingeniería  
Facultad de Ingeniería Económica, Estadística y Ciencias Sociales  
Escuela Profesional de Ingeniería Estadística

*Último Informe de Investigación*

# Proyección de la Producción de Anchoveta en Perú Incorporando Indicadores Climáticos del Océano Pacífico

## Consultoría Estadística

Docente: *Grados Paredes Daniel*

**Lin Chiu Chen Yang<sup>2</sup>   Ocaña Coronado Manuel<sup>3</sup>   Varillas Torres Augusto<sup>4</sup>**

### Abstract

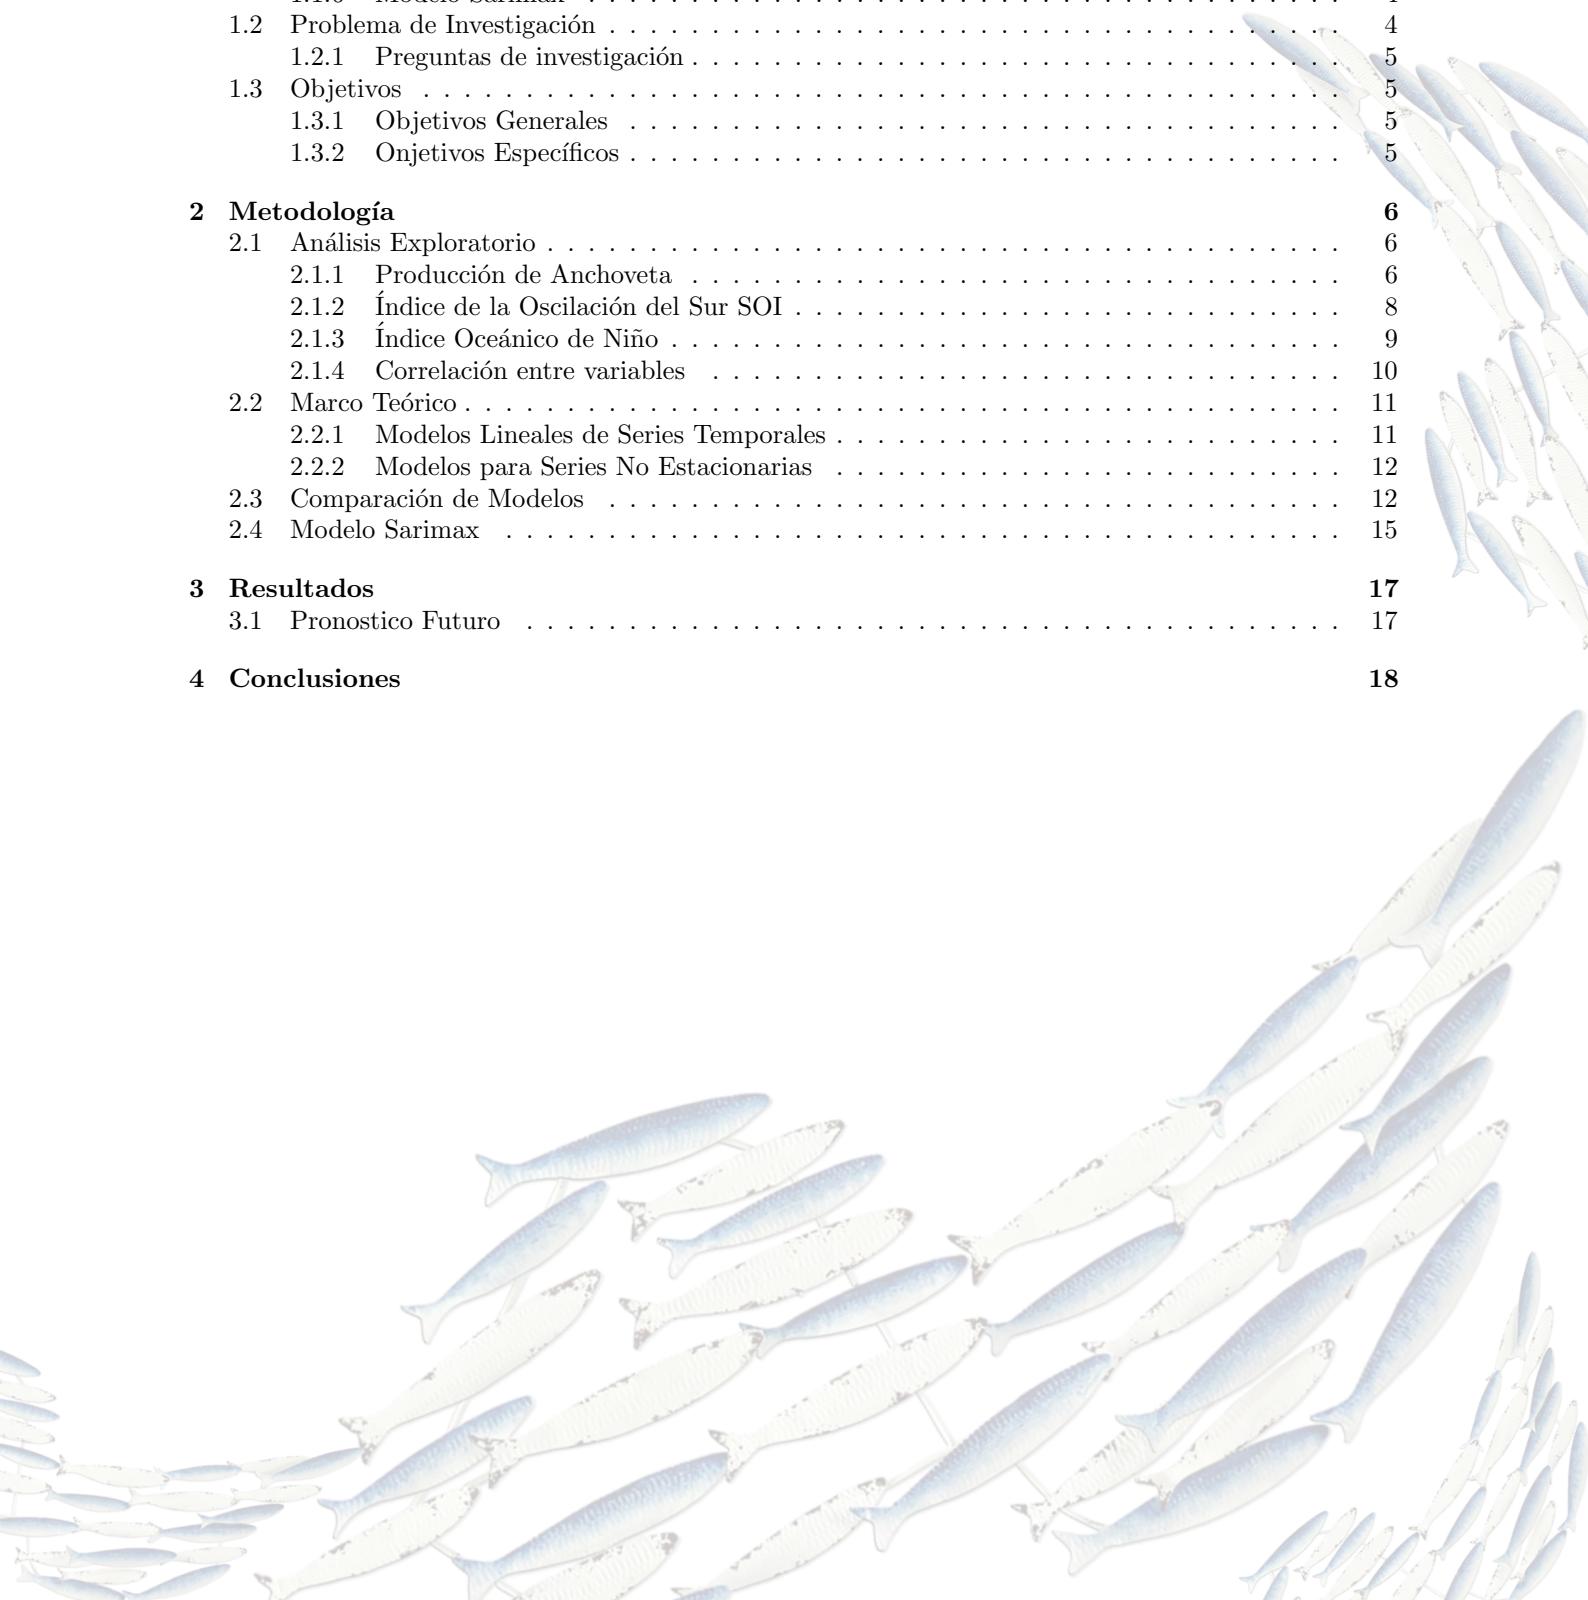
Este informe presenta un análisis estadístico orientado a modelar la producción pesquera mensual de anchoveta en el Perú, considerando el impacto de variables climáticas como el índice de oscilación del niño (ONI) y el índice de oscilación del sur (SOI). El objetivo es generar un modelo predictivo que permita proyectar la producción para los próximos cinco meses, facilitando la toma de decisiones por parte de la industria pesquera.

Utilizando datos mensuales desde 2003 hasta 2025 obtenidos a través del Banco Central de Reserva del Perú y National Oceanic and Atmospheric Administration, se aplicaron técnicas de modelado de series de tiempo específicamente con el SARIMAX. El modelo desarrollado permite realizar proyecciones con un nivel aceptable de error y brinda información relevante sobre la sensibilidad de la producción frente a cambios climáticos.

**keywords** Producción pesquera, anchoveta, clima, sarimax, Perú

## Contents

<b>1</b>	<b>Introducción</b>	<b>2</b>
1.1	Contexto . . . . .	2
1.1.1	La Familia Engraulidae . . . . .	2
1.1.2	La Anchoveta Peruana y su Importancia Económica . . . . .	2
1.1.3	Medidas de Gestión y Sostenibilidad . . . . .	3
1.1.4	Amenaza Latente del Efecto Climático . . . . .	3
1.1.5	Estudios Anteriores . . . . .	3
1.1.6	Modelo Sarimax . . . . .	4
1.2	Problema de Investigación . . . . .	4
1.2.1	Preguntas de investigación . . . . .	5
1.3	Objetivos . . . . .	5
1.3.1	Objetivos Generales . . . . .	5
1.3.2	Objetivos Específicos . . . . .	5
<b>2</b>	<b>Metodología</b>	<b>6</b>
2.1	Análisis Exploratorio . . . . .	6
2.1.1	Producción de Anchoveta . . . . .	6
2.1.2	Índice de la Oscilación del Sur SOI . . . . .	8
2.1.3	Índice Oceánico de Niño . . . . .	9
2.1.4	Correlación entre variables . . . . .	10
2.2	Marco Teórico . . . . .	11
2.2.1	Modelos Lineales de Series Temporales . . . . .	11
2.2.2	Modelos para Series No Estacionarias . . . . .	12
2.3	Comparación de Modelos . . . . .	12
2.4	Modelo Sarimax . . . . .	15
<b>3</b>	<b>Resultados</b>	<b>17</b>
3.1	Pronóstico Futuro . . . . .	17
<b>4</b>	<b>Conclusiones</b>	<b>18</b>



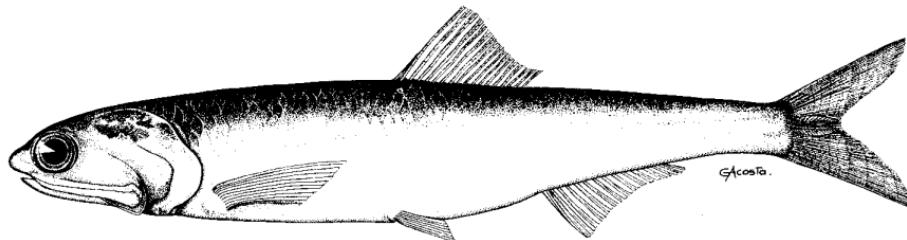


Fig. 1 Ejemplar adulto de anchoveta Engraulis ringens J.

## 1 Introducción

### 1.1 Contexto

#### 1.1.1 La Familia Engraulidae

La familia Engraulidae dentro de la orden de los Clupeiformes son peces con nombres como aladroque, bocarte, boquerón según la (RAE, 2025) comúnmente conocidos como anchoa, habitan en la zona *pelágica* en grandes cardúmenes en aguas costeras dentro de 80 Km hasta una profundidad de 50 metros se caracterizan por un tamaño aproximado entre 15cm y 20cm de color azul intenso clasificándose como pescado azul como el atún, el salmón o la caballa; también llamado pescado graso por tener un mayor porcentaje de grasa en su masa muscular en comparación con los pescados blancos como la merluza o el bacalao. Se distribuyen en los océanos Atlántico, Pacífico e Índico, así como en el mar Mediterráneo incluso algunas en lagos de agua dulce teniendo varias variantes como la anchoa europea, argentina, californiana, japonesa, africana y por último la peruana con mayor relevancia comercial en el ámbito mundial según el último boletín publicado por la (FAO, 2024). Por su alto contenido graso se pescan para el consumo humano y el procesamiento industrial principalmente en conservas, arina y aceite de pescado.

#### 1.1.2 La Anchoveta Peruana y su Importancia Económica

La anchoveta peruana, cuyo nombre científico es "Engraulis ringens" se encuentra en el sureste del Océano Pacífico frente a Perú y Chile entre 4° a 42° latitud sur y 82° a 69° longitud oeste (FishBase, 2025); se reproducen durante todo el año con preferencia en épocas de invierno hasta fines de primavera demorando alrededor de 1 año en llegar a la edad adulta, concentrando las crías cerca de las primeras millas de la costa, tiene una longevidad corta de 3 años ; la abundancia de esta se debe al afloramiento de las aguas por la corriente peruana o de Humboldt, que transporta las aguas frías del continente antártico en dirección hacia el norte para encontrarse con la corriente cálida del niño, transportando ricos nutrientes como fitoplancton y zooplancton creando el ecosistema más abundante y productivo del planeta. La anchoveta es la especie más representativa procedente de la pesca llegando a máximos de hasta 13 millones de toneladas en los 90; actualmente este número ha descendido; en 2022 se llegó a pescar hasta 4.8 millones de toneladas (FAO, 2025) esta representa el 9.4% de la pesca mundial, de las cuales Perú abarca el 6.6% aportando el 0.8% del producto bruto interno PBI reflejado en el informe de (BCRP, 2024) de las cuales el 80% es anchoveta.

### 1.1.3 Medidas de Gestión y Sostenibilidad

Si bien, somos el primer productor mundial, la Organización de las Naciones Unidas ONU está impulsando una agenda de desarrollo sostenible reflejando en los últimos años el crecimiento acelerado de la producción por acuicultura igualando a la producción por pesca pero según (Peruano, 2016) en el Perú solo una quinta parte del PBI del sector de pesca es acuicultura estamos alejados de la tendencia. La experiencia pasada nos ha demostrado las consecuencias de la sobreexplotación como el caso de los 70 (Arias Schreiber, 2012) la reducción drástica de la población de anchovetas ha hecho al estado efectuar políticas de gestión pesquera sostenible y monitoreo constante por el Instituto del Mar del Perú IMARPE y limitación de su pesca por el Ministerio de Producción considerando la cantidad máxima de captura, el tamaño mínimo aceptable, estableciendo zonas y temporadas de pesca finalmente, la promoción de medidas de su conservación manteniendo a la especie en preocupación menor; sin embargo, en multiples ocasiones la variabilidad climática ha jugado un papel dominante en la vulnerabilidad de la anchoveta disminuyendo drásticamente la población de esta, como podemos observar en los años 72, 80, 97 y 2015 los eventos son cada vez más frecuentes por el cambio climático según (Oliveros-Ramos and Shin, 2023a) la población se está reduciendo a una tasa del 14% por década llegando a desaparecer para el 2060 estamos hablando nada más que el fenómeno del niño conocido como El Niño - Oscilación del Sur ENSO un fenómeno climático global que ocurre al calentarse las aguas en el océano Pacífico tropical

### 1.1.4 Amenaza Latente del Efecto Climático

La producción pesquera, especialmente en ecosistemas tan dinámicos como el del Pacífico sudoriental, está fuertemente influenciada por la variabilidad climática interanual y multidecenal. En particular, el fenómeno de El Niño-Oscilación del Sur (ENSO) representa una amenaza significativa para la estabilidad de las poblaciones de anchoveta (*Engraulis ringens*), debido al calentamiento anómalo de las aguas superficiales del Pacífico ecuatorial que altera los patrones de afloramiento y, en consecuencia, la disponibilidad de nutrientes (Chavez et al., 2003). Durante eventos de El Niño, la temperatura superficial del mar se incrementa, lo que disminuye la concentración de fitoplancton y zooplancton, principales fuentes de alimento de la anchoveta (Bakun and Weeks, 2008). Esto provoca una migración de la especie hacia zonas más profundas o alejadas de la costa, reduciendo su disponibilidad para la pesca y afectando severamente los niveles de captura (Ñiquen and Bouchon, 2004). Estos eventos no solo producen fluctuaciones económicas en el sector pesquero, sino que también afectan los ecosistemas marinos en su conjunto, generando impactos en las cadenas tróficas (Barber and Chavez, 1983). Además, estudios recientes han alertado sobre el aumento en la frecuencia e intensidad de los eventos ENSO en el contexto del cambio climático global, lo que pone en mayor riesgo a las especies dependientes del afloramiento costero como la anchoveta (Timmermann et al., 2018). Modelos ecológicos y climáticos han proyectado que, de continuar esta tendencia, las poblaciones de anchoveta podrían reducirse significativamente en las próximas décadas, comprometiendo la seguridad alimentaria y la economía pesquera del Perú (Oliveros-Ramos and Shin, 2023b). Ante este escenario, resulta imperativo comprender mejor la relación entre las condiciones oceánicas y la producción pesquera, incorporando indicadores climáticos como el ONI (Oceanic Niño Index) y el SOI (Southern Oscillation Index) en los modelos predictivos que orienten la gestión sostenible del recurso.

### 1.1.5 Estudios Anteriores

La relación entre la dinámica poblacional de la anchoveta (*Engraulis ringens*) y las condiciones ambientales del Pacífico sudoriental ha sido objeto de numerosas investigaciones, en las que se ha evidenciado una marcada sensibilidad de esta especie a la variabilidad climática. Particularmente, los eventos asociados al fenómeno El Niño-Oscilación del Sur (ENSO) influyen significativamente en la distribución, abundancia y capturabilidad de la anchoveta, afectando con ello la sostenibilidad de la pesquería. En este contexto, (Ñiquen and Bouchon, 2004) analizaron el impacto de los eventos El Niño sobre la pesquería de anchoveta en el Perú, concluyendo que dichos eventos generan alteraciones en su hábitat, desplazamiento hacia zonas menos accesibles y una reducción significativa en los volúmenes de captura. De manera complementaria, (Bertrand et al., 2004) propusieron una hipótesis basada en el hábitat para explicar las fluctuaciones en las poblaciones de peces pelágicos, argumentando que la interacción entre procesos oceanográficos de

pequeña escala y ciclos climáticos de mayor duración condiciona la estructura poblacional y la productividad pesquera. Asimismo, (Bertrand et al., 2008) analizaron cómo el comportamiento de los cardúmenes de anchoveta responde a los forzantes ambientales, como la temperatura y la productividad primaria, demostrando que la distribución de la anchoveta puede cambiar significativamente debido a alteraciones ambientales. Más recientemente, (Oliveros-Ramos and Shin, 2023b) proyectaron escenarios de reducción de biomasa bajo el contexto del cambio climático, sugiriendo que, si no se toman medidas de gestión adaptativa, la población de anchoveta podría experimentar un declive del 14% por década, comprometiendo su viabilidad a largo plazo. Estos antecedentes sustentan la necesidad de incorporar información climática en los modelos de predicción pesquera. En este sentido, el presente estudio propone un enfoque cuantitativo basado en series temporales que incorpore índices climáticos como ONI 1+2, ONI 3.4 y el SOI, con el fin de generar proyecciones de corto plazo y apoyar la toma de decisiones en la industria pesquera nacional.

### 1.1.6 Modelo Sarimax

Un estudio análogo al presente trabajo fue desarrollado por (Raman et al., 2018) en la laguna de Chilika, India, una reserva Ramsar reconocida por su biodiversidad y actividad pesquera. En dicho estudio, los autores emplearon un modelo SARIMAX para predecir los desembarques mensuales de peces, integrando variables ambientales como salinidad, temperatura, alcalinidad y transparencia del agua. El modelo ajustado fue un SARIMA con tres variables exógenas, encontrando que el primer factor (dominado por salinidad y temperatura) tenía un efecto positivo y significativo sobre la captura. El modelo logró una precisión predictiva del 93%, con errores entre 3% y 7% al ser validado con datos reales de los años 2011 a 2015. Finalmente, el SARIMAX permitió proyectar las capturas hasta marzo de 2018, demostrando ser una herramienta eficaz para la gestión pesquera en entornos afectados por variabilidad ambiental. Este antecedente refuerza la pertinencia del enfoque aplicado en el presente trabajo, que propone un modelo SARIMAX para la predicción mensual de anchoveta peruana (*Engraulis ringens*), incorporando los índices climáticos ONI 1+2, ONI 3.4 y SOI como variables exógenas. Al igual que en Chilika, se reconoce que factores ambientales (en este caso climáticos) desempeñan un rol determinante en las fluctuaciones de la biomasa pesquera, justificando la integración cuantitativa de dichas variables en modelos estadísticos para la toma de decisiones en contextos de alta incertidumbre.

## 1.2 Problema de Investigación

La gestión eficaz de la pesquería de anchoveta y la operatividad de la industria asociada dependen críticamente de la disponibilidad de pronósticos confiables sobre la abundancia y disponibilidad del recurso a corto plazo (escala mensual). Decisiones como la fijación de cuotas de captura por temporada, la determinación de las fechas de inicio y cierre de las vedas, la movilización de la flota pesquera y las inversiones en la cadena de procesamiento requieren una estimación lo más precisa posible de los volúmenes de desembarque esperados.

### El Desafío de la Variabilidad Climática

La principal fuente de incertidumbre y volatilidad en la pesquería de anchoveta es la variabilidad climática interanual, especialmente los eventos ENOS (El Niño y La Niña). Estos fenómenos alteran drásticamente las condiciones oceanográficas del SCH (Sistema de la Corriente de Humboldt), afectando la biomasa, distribución y comportamiento de la anchoveta de maneras que no siempre son predecibles con métodos simples según (Bouchon, 2019). Esta volatilidad climática dificulta enormemente la planificación y aumenta el riesgo operativo y económico para el sector.

### Integración de Datos Climáticos

Si bien la influencia del clima en la anchoveta es bien conocida, el desafío operativo consiste en integrar sistemática y cuantitativamente esta información en los modelos de pronóstico. Según (Sherman, 2015), existen índices climáticos estandarizados y de fácil acceso (como ONI 1+2, ONI 3.4 y SOI) que resumen diferentes aspectos del estado del sistema océano-atmósfera en el Pacífico. La inclusión de estos tres índices

permite evaluar de manera diferenciada la influencia de las condiciones térmicas en el Pacífico central, las condiciones térmicas costeras y la respuesta atmosférica a gran escala sobre los desembarques de anchoveta. No se trata solo de confirmar que el clima importa, sino de discernir qué aspectos específicos del sistema climático, representados por estos índices distintos, ofrecen la mayor capacidad predictiva para la pesquería peruana. La cuantificación de la importancia relativa de cada uno es, por tanto, un componente esencial del problema a resolver.

### 1.2.1 Preguntas de investigación

En función del problema planteado, esta investigación se orienta a responder las siguientes preguntas:

1. ¿Cuál es el comportamiento mensual de la producción pesquera de anchoveta en el Perú desde una perspectiva temporal y climática?
2. ¿Qué influencia tienen los índices climáticos ONI 1+2, ONI 3.4 y SOI sobre la variación en la producción mensual de anchoveta?
3. ¿Puede desarrollarse un modelo estadístico, como el SARIMAX, que integre estas variables climáticas para proyectar con precisión la producción de anchoveta en los próximos cinco meses?
4. ¿Qué nivel de precisión y capacidad explicativa ofrece el modelo en comparación con enfoques tradicionales no climáticos?

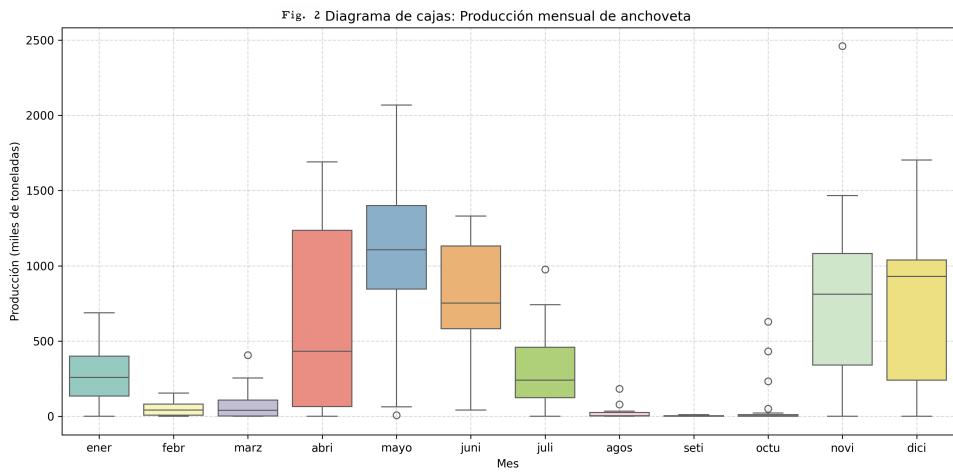
## 1.3 Objetivos

### 1.3.1 Objetivos Generales

Desarrollar y presentar un pronóstico estadístico de la producción mensual de anchoveta peruana (*Engraulis ringens*), expresada en miles de toneladas métricas (TM), para los próximos cinco meses consecutivos, incorporando intervalos de confianza que cuantifiquen la incertidumbre predictiva asociada.

### 1.3.2 Objetivos Específicos

1. Construir un modelo de pronóstico de series de tiempo, preferentemente un modelo SARIMAX, que incorpore explícitamente los valores mensuales históricos del Índice Oceánico Niño 1+2 (ONI 1+2), el Índice Oceánico Niño 3.4 (ONI 3.4) y el Índice de Oscilación del Sur (SOI) como variables exógenas predictoras de la producción de anchoveta.
2. Evaluar estadísticamente la relación histórica entre la producción mensual de anchoveta y los índices climáticos seleccionados, considerando posibles efectos de desfase temporal (lags).
3. Realizar un análisis de importancia de variables para cuantificar la contribución relativa y la significancia estadística de cada índice climático (ONI 1+2, ONI 3.4, SOI) en la predicción de la producción pesquera de anchoveta, dentro del contexto del modelo desarrollado (Yadav, 2021).
4. Estructurar y presentar los hallazgos del análisis en función de su aplicabilidad para la planificación y gestión de la producción pesquera de anchoveta en el Perú.



## 2 Metodología

## 2.1 Análisis Exploratorio

### 2.1.1 Producción de Anchoveta

Esta es nuestra ***variable respuesta*** obtenida a travez del Banco Central de Reserva del Perú BCRP (BCRP, 2025) detalla la produccion pesquera de la anchoveta peruana en miles de toneladas de cada mes desde el año 2003 hasta enero del 2025 teniendo un total de 265 observaciones, lo que permite realizar

**Tabla 1:** Producción mensual de anchoveta peruana en miles de toneladas.

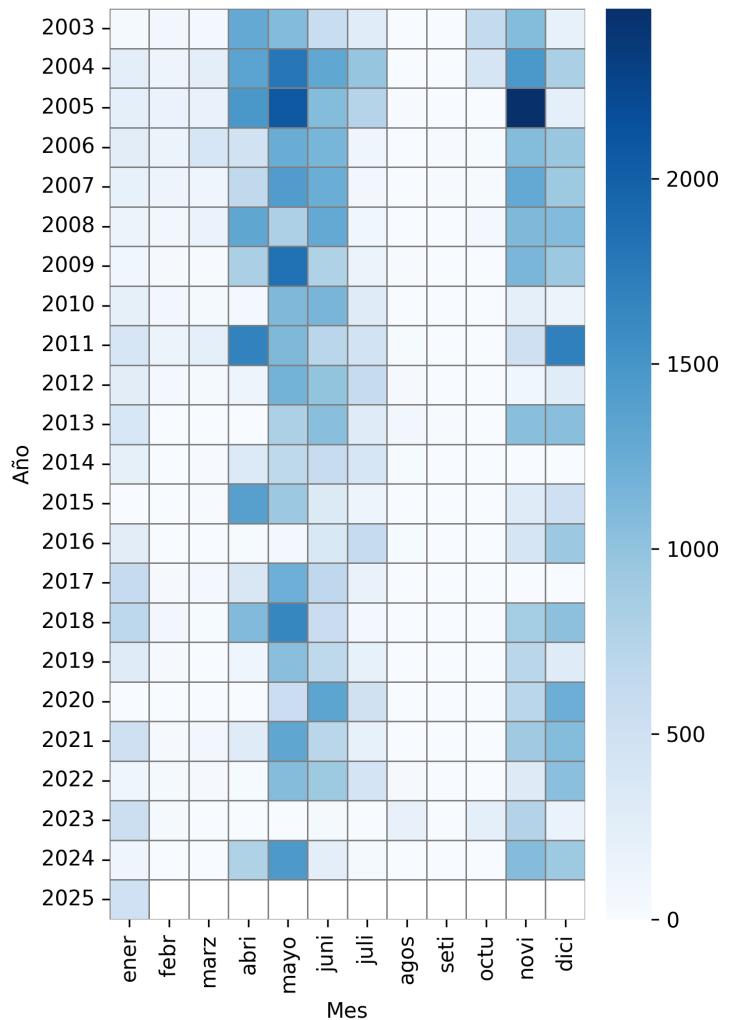


Figure 1: mapa de calor de los datos)

visualizar la variación mensual de la producción a lo largo de los años. En esta representación, cada celda muestra la producción mensual codificada por color, lo que facilita identificar patrones de alta o baja actividad pesquera de forma más intuitiva que con tablas numéricas o gráficos convencionales. El análisis del mapa de calor refuerza los hallazgos del diagrama de cajas: los años muestran una tendencia clara a concentrar la mayor producción en los meses de mayo y noviembre. Se observa también que durante ciertos años —especialmente en eventos como El Niño (por ejemplo, 2015-2016)— las celdas correspondientes a meses productivos presentan colores más claros (baja producción), lo cual refleja el impacto negativo que estos eventos climáticos extremos tienen sobre la disponibilidad de anchoveta. Desde una perspectiva de análisis multitemporal, el mapa de calor también sugiere que si bien existe una estacionalidad recurrente, hay una variabilidad interanual importante en la intensidad de la producción, lo cual refuerza la necesidad de considerar variables climáticas. En conjunto, este análisis exploratorio permite no solo caracterizar la distribución temporal de la producción de anchoveta, sino también entender cómo las decisiones políticas y los factores ambientales interactúan para influir en esta actividad económica clave para el país.

un análisis robusto de los patrones estacionales y de variabilidad interanual. En la Figura 1, que presenta un diagrama de cajas y bigotes de la producción mensual, se puede observar una marcada estacionalidad. Los meses con mayor producción tienden a ser mayo y noviembre, mientras que durante agosto, septiembre y octubre la actividad pesquera es casi nula. Esta estacionalidad no es aleatoria ni atribuible a factores externos imprevistos, sino que obedece a una regulación formal del Ministerio de la Producción, que establece dos temporadas principales de pesca de anchoveta cada año: la primera temporada suele abarcar desde finales de marzo o abril hasta junio, y la segunda se desarrolla principalmente entre noviembre y diciembre. Estas fechas pueden variar ligeramente cada año y son oficializadas mediante resoluciones ministeriales. Este patrón estacional responde no solo a criterios de sostenibilidad biológica del recurso, sino también a condiciones oceanográficas que favorecen la disponibilidad de anchoveta durante ciertas épocas del año. Por ello, además del calendario administrativo, los científicos del Instituto del Mar del Perú (IMARPE) evalúan constantemente la biomasa de la especie antes de recomendar la apertura de las temporadas de pesca. Para complementar la exploración gráfica de la estacionalidad en la producción de anchoveta, se construyó un mapa de calor que permite

### 2.1.2 Índice de la Oscilación del Sur SOI

El Índice de la Oscilación del Sur (SOI) constituye nuestra primera variable explicativa en el análisis del comportamiento de la producción mensual de anchoveta. Este índice representa la diferencia estandarizada de presión atmosférica a nivel del mar entre la isla polinesia Tahití y Darwin en Australia y se utiliza ampliamente como un indicador de la presencia e intensidad de los fenómenos climáticos El Niño y La Niña, los cuales influyen significativamente en las condiciones oceanográficas del Pacífico Oriental, especialmente frente a las costas del Perú.

Valores negativos del SOI están asociados con la presencia del fenómeno de El Niño, caracterizado por el calentamiento anómalo del mar, menor afloramiento de nutrientes y, por ende, una reducción en la biomasa de anchoveta. Por otro lado, valores positivos del SOI indican condiciones de La Niña, asociadas a un enfriamiento del mar y, en algunos casos, a un incremento en la productividad marina.

En este contexto, el SOI es una variable relevante ya que permite incorporar en el modelo explicativo un componente climático-atmosférico que, aunque externo al ecosistema marino local, tiene efectos directos sobre el comportamiento de la especie. Se espera, por tanto, que exista una correlación inversa entre el SOI y la producción de anchoveta en meses afectados por El Niño, y una posible correlación positiva durante eventos de La Niña.

Para el presente estudio, se han considerado los valores mensuales del SOI desde el año 2003 hasta el 2025, obtenidos de fuentes oficiales como el Administración Nacional Oceánica y Atmosférica NOAA (NOAA, 2025b). En las siguientes secciones se analizará su comportamiento temporal, se contrastará con la producción de anchoveta y se evaluará su incorporación como predictor en los modelos estadísticos propuestos.

**Tabla 2:** Índice estandarizado de la Oscilación del Sur.

año	ener	febr	marz	abri	mayo	juni	juli	agos	seti	octu	novi	dici
2003	-0.2	-0.7	-0.3	-0.1	-0.3	-0.6	0.3	0.1	-0.1	0.0	-0.3	1.1
2004	-1.3	1.2	0.4	-0.9	1.0	-0.8	-0.5	-0.3	-0.3	-0.1	-0.7	-0.8
2005	0.3	-3.1	0.3	-0.6	-0.8	0.4	0.2	-0.3	0.4	1.2	-0.2	-0.0
2006	1.7	0.1	1.8	1.1	-0.5	-0.2	-0.6	-1.0	-0.6	-1.3	0.1	-0.3
2007	-0.8	-0.1	0.2	-0.1	-0.1	0.5	-0.3	0.4	0.2	0.7	0.9	1.7
2008	1.8	2.6	1.4	0.7	-0.1	0.6	0.3	1.0	1.2	1.3	1.3	1.4
2009	1.1	1.9	0.4	0.8	-0.1	0.1	0.2	-0.2	0.3	-1.2	-0.6	-0.7
2010	-1.1	-1.5	-0.7	1.2	0.9	0.4	1.8	1.8	2.2	1.7	1.3	2.9
2011	2.3	2.7	2.5	1.9	0.4	0.2	1.0	0.4	1.0	0.8	1.1	2.5
2012	1.1	0.5	0.7	-0.3	0.0	-0.4	-0.0	-0.2	0.2	0.3	0.3	-0.6
2013	-0.1	-0.2	1.5	0.2	0.8	1.2	0.8	0.2	0.3	-0.1	0.7	0.1
2014	1.4	0.1	-0.9	0.8	0.5	0.2	-0.2	-0.7	-0.7	-0.6	-0.9	-0.6
2015	-0.8	0.2	-0.7	-0.0	-0.7	-0.6	-1.1	-1.4	-1.6	-1.7	-0.5	-0.6
2016	-2.2	-2.0	-0.1	-1.2	0.4	0.6	0.4	0.7	1.2	-0.3	-0.1	0.3
2017	0.2	-0.1	0.9	-0.2	0.3	-0.4	0.8	0.5	0.6	0.9	0.9	-0.1
2018	1.1	-0.5	1.5	0.5	0.4	-0.1	0.2	-0.3	-0.9	0.4	-0.1	1.0
2019	-0.0	-1.4	-0.3	0.1	-0.4	-0.5	-0.4	-0.1	-1.2	-0.4	-0.8	-0.6
2020	0.2	-0.1	-0.1	0.2	0.4	-0.4	0.4	1.1	0.9	0.5	0.7	1.8
2021	1.9	1.5	0.4	0.3	0.5	0.4	1.4	0.6	0.8	0.7	1.0	1.5
2022	0.5	1.1	1.8	1.7	1.4	1.7	0.8	1.0	1.6	1.7	0.3	2.1
2023	1.4	1.4	0.2	0.2	-1.0	0.3	-0.3	-0.8	-1.3	-0.5	-0.8	-0.2
2024	0.5	-1.4	0.4	-0.2	0.5	0.0	-0.7	0.9	-0.1	0.5	0.5	1.2
2025	0.2	0.5	1.7	0.4								

Los datos se obtuvieron a partir de la diferencia entre las presiones atmosféricas al nivel del mar (SLP - presión a nivel del mar) de Tahití y Darwin, estandarizadas con base en un período de referencia (1981–2010).

$$SOI = \frac{s_{SLP_{Tahiti}} - s_{SLP_{Darwin}}}{\sigma_{mensual}}$$

Para ello, primero se calcula la presión estandarizada ( $sSLP$ ) en cada ubicación, la cual se obtiene restando a la presión real ( $aSLP$ ) su media ( $mSLP$ ) y dividiendo el resultado entre la desviación estándar ( $\sigma$ ) de dicha serie.

$$sSLP = \frac{aSLP - mSLP}{\sigma}$$

donde  $\sigma$  es

$$\sigma = \sqrt{\frac{\sum(aSLP - mSLP)^2}{N}}$$

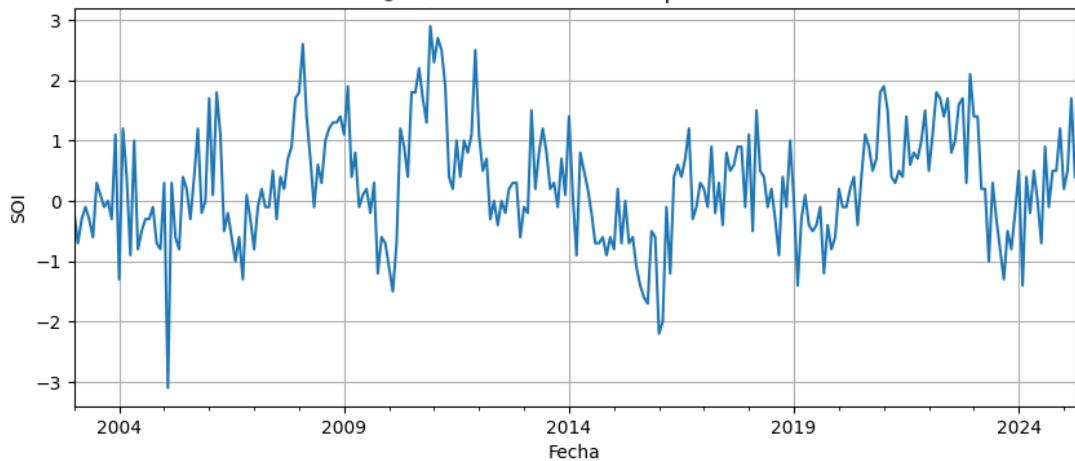
Luego, el índice SOI se obtiene como la diferencia entre las presiones estandarizadas de Tahití y Darwin, dividida entre la desviación estándar mensual

$$\sigma_{mensual} = \sqrt{\frac{\sum(sSLP_{Tahiti} - sSLP_{Darwin})^2}{N}}$$

de esa diferencia para el periodo base. Este proceso permite expresar el SOI en términos de desviaciones estándar, facilitando la comparación temporal y la detección de eventos extremos como El Niño y La Niña.

Al emplear una visualización de los datos podemos observar la evolución a largo plazo del SOI refleja un patrón oscilante con períodos prolongados de valores predominantes positivos o negativos sin tendencia ni estacionalidad.

**Fig. 4 Índice SOI - Serie temporal**

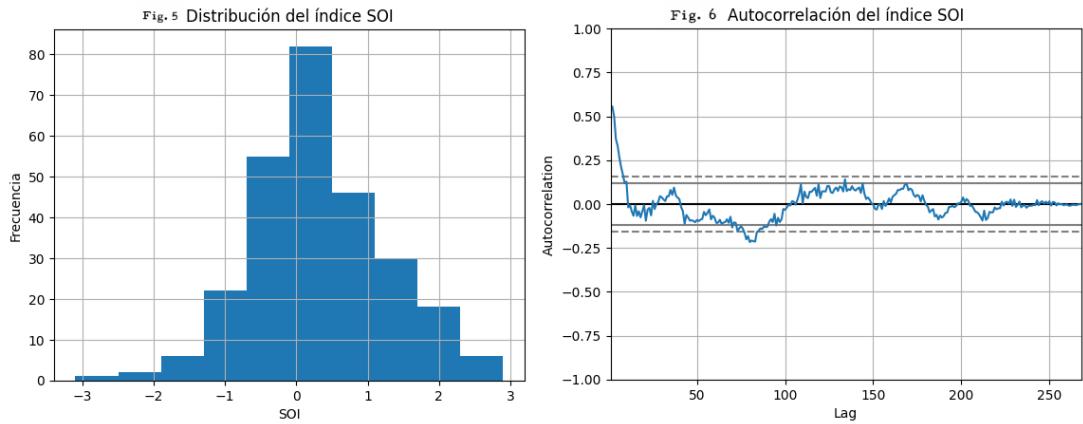


al ver su distribución observamos que predomina valores positivos lo cual explica la esporadicidad del niño; en el gráfico de autocorrelación muestra que no tiene tendencia ni periodicidad con rezagos positivos o negativos que se mantienen durante meses consecutivos sugiere que esta serie presenta memoria a corto y mediano plazo, así como una estructura cíclica importante. Esto la convierte en una candidata adecuada para modelado con técnicas como ARIMA estacional, modelos autorregresivos o incluso enfoques espectrales o de series de tiempo multivariantes si se desea incorporar variables climáticas adicionales.

### 2.1.3 Índice Oceánico de Niño

El Índice Oceánico de Niño (ONI) corresponde a nuestra segunda variable explicativa, también de carácter climático. Este índice mide la anomalía de temperatura superficial del mar (TSM) en la región del Pacífico ecuatorial, que abarca la zona costera del norte de Perú y el sur de Ecuador. Dicha región es de particular interés, ya que se encuentra directamente influenciada por las condiciones oceanográficas locales que afectan la distribución y abundancia de la anchoveta.

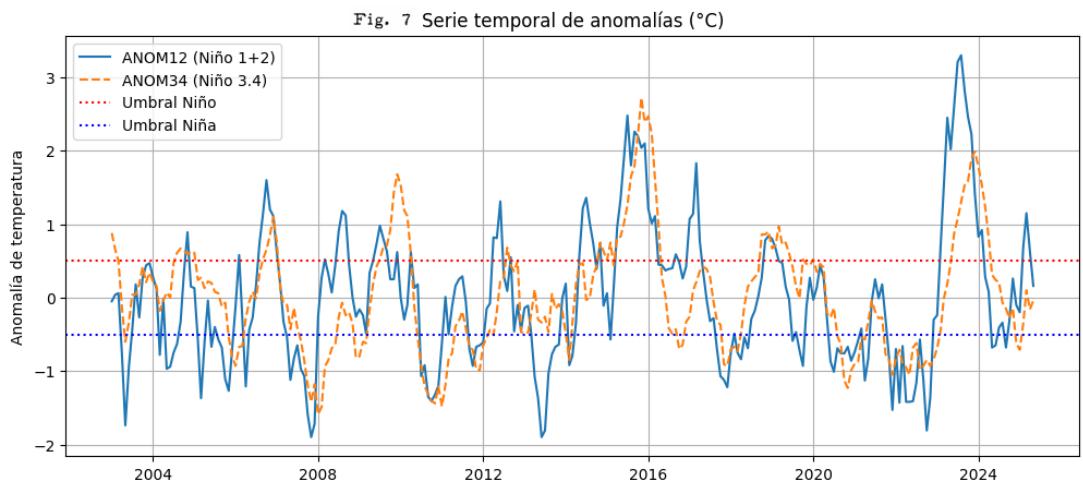
A diferencia del SOI, que se basa en datos atmosféricos, el ONI se centra en registros oceanográficos y refleja de manera más directa el calentamiento o enfriamiento del mar en la zona de pesca peruana.



Valores positivos del índice indican el desarrollo de condiciones cálidas asociadas al fenómeno de El Niño costero, mientras que valores negativos sugieren enfriamiento y condiciones favorables para la pesca.

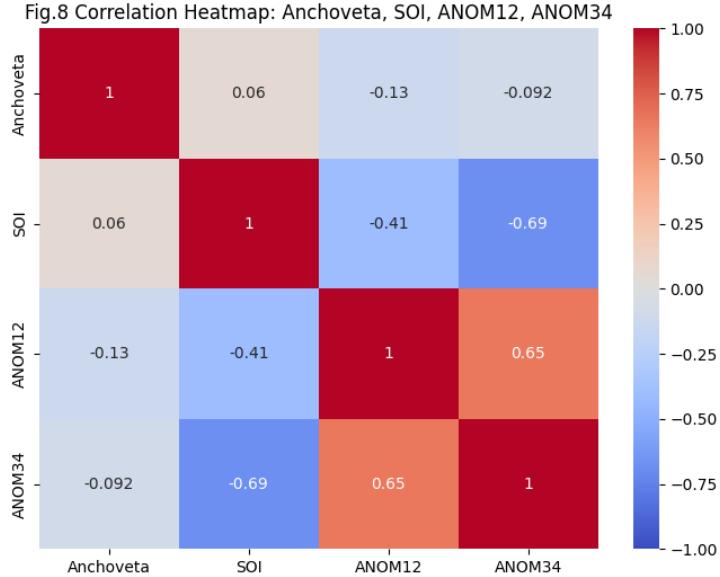
Este índice resulta especialmente útil para detectar eventos de El Niño costero, los cuales pueden tener impactos significativos sobre la biomasa de anchoveta aun cuando no se registre un evento Niño clásico a nivel global. Por ello, el análisis de la evolución mensual del ONI 1+2 proporciona información clave para comprender las fluctuaciones en la producción de anchoveta, especialmente en años atípicos como 2017.

Los datos históricos del ONI fueron obtenidos del Centro de Predicción Climática de la NOAA (NOAA, 2025a), y se analizarán en conjunto con las demás variables climáticas para explorar posibles correlaciones y efectos rezagados en la producción pesquera.



Al revisar los datos observamos una correlación del 0.65 entre las anomalías de las regiones 1+2 y 3.4. El gráfico refleja un comportamiento típico del fenómeno ENSO, con ciclos de El Niño y La Niña. Ambas series muestran una variabilidad significativa a lo largo del tiempo, con picos y caídas que reflejan eventos de El Niño y La Niña. ANOM1+2 tiende a tener amplitudes más pronunciadas. Los últimos años muestran un aumento en la intensidad de los eventos, particularmente en 2023-2024, lo que podría tener implicaciones para el clima global.

#### 2.1.4 Correlación entre variables



La matriz de correlación revela las relaciones entre la producción de anchoveta, el índice SOI, y las anomalías ONI para las regiones 1+2 (ANOM12) y 3.4 (ANOM34). La producción de anchoveta muestra una correlación positiva pero muy débil con el SOI (0.06), sugiriendo que las condiciones asociadas con La Niña (SOI positivo) no tienen un impacto lineal fuerte en la producción. Por otro lado, las correlaciones negativas de la producción con ANOM12 (-0.13) y ANOM34 (-0.092) indican una leve tendencia a disminuir durante eventos de El Niño (anomalías positivas), aunque estas relaciones son débiles. Entre las variables climáticas, el SOI muestra correlaciones moderadas con ANOM12 (-0.41) y ANOM34 (-0.69), consistente con su

comportamiento opuesto durante ENSO, mientras que ANOM12 y ANOM34 están positivamente correlacionadas (0.65), reflejando su sincronía en las regiones Niño.

Estas correlaciones, sugieren influencias climáticas sutiles en la producción de anchoveta, pero la baja magnitud indica que otros factores (como esfuerzo pesquero o variabilidad estacional) podrían estar jugando un papel importante.

## 2.2 Marco Teórico

Una serie temporal es una secuencia de datos observados en momentos sucesivos, usualmente espaciados en intervalos de tiempo iguales (diarios, mensuales, anuales, etc.). El análisis de series temporales se enfoca en modelar la estructura de dependencia temporal entre observaciones pasadas y presentes, con el objetivo de entender su comportamiento, identificar patrones (como tendencia y estacionalidad) y generar pronósticos futuros.

A diferencia del análisis clásico de datos, donde las observaciones se consideran independientes, en las series temporales la autocorrelación juega un rol central: el valor actual de la serie suele depender de sus valores pasados.

### 2.2.1 Modelos Lineales de Series Temporales

**Modelo Autorregresivo (AR)** El modelo autorregresivo de orden  $p$ , denotado AR( $p$ ), supone que el valor actual de la serie puede explicarse como una combinación lineal de sus  $p$  valores pasados más un término de error aleatorio:

$$Y_t = c + \sum_{i=1}^p \phi_i Y_{t-i} + \epsilon_t$$

donde  $\epsilon_t$  es un ruido blanco. Este modelo es útil cuando los datos muestran una dependencia fuerte entre observaciones sucesivas.

**Modelo de Media Móvil (MA)** El modelo de media móvil de orden  $q$ , MA( $q$ ), modela el valor actual de la serie como una combinación lineal de los errores aleatorios pasados:

$$Y_t = \mu + \epsilon_t + \sum_{j=1}^q \theta_j \epsilon_{t-j}$$

Este modelo es apropiado cuando la dependencia se manifiesta principalmente en los errores de predicción.

**Modelo Autorregresivo de Media Móvil (ARMA)** Cuando la serie es estacionaria y combina características de los modelos AR y MA, se puede emplear el modelo ARMA(p,q):

$$c + \sum_{i=1}^p \phi_i Y_{t-i} + \epsilon_t + \sum_{j=1}^q \theta_j \epsilon_{t-j}$$

### 2.2.2 Modelos para Series No Estacionarias

Muchas series temporales reales no son estacionarias, es decir, presentan tendencias, cambios de varianza o estacionalidad. Para trabajar con estas series, se utilizan extensiones del modelo ARMA.

**Modelo Autorregresivo Integrado de Media Móvil (ARIMA)** El modelo ARIMA(p,d,q) permite trabajar con series no estacionarias mediante la diferenciación de orden d, transformando la serie original en una serie estacionaria:

$$\Delta^d Y_t = c + \sum_{i=1}^p \phi_i \Delta^d Y_{t-i} + \epsilon_t + \sum_{j=1}^q \theta_j \epsilon_{t-j}$$

Este modelo es ampliamente utilizado en contextos donde la serie muestra tendencias pero no estacionalidad.

#### Modelo ARIMA Estacional (SARIMA)

Cuando una serie presenta patrones estacionales (por ejemplo, mensuales, trimestrales o anuales), se requiere incorporar componentes estacionales. El modelo  $SARIMA(p, d, q)(P, D, Q)_s$  añade términos autorregresivos y de media móvil estacionales con un período estacional s:

$$SARIMA(p, d, q)(P, D, Q)_s$$

Este modelo captura tanto la estructura temporal regular como la estacional.

**Modelo SARIMA con Variables Exógenas (SARIMAX)** El modelo SARIMAX (Seasonal ARIMA with eXogenous variables) extiende el modelo SARIMA al incluir una o más variables externas (exógenas), que pueden influir sobre la serie de interés. Se representa como:

$$Y_t = SARIMA(p, d, q)(P, D, Q)_s + \beta X_t + \epsilon_t$$

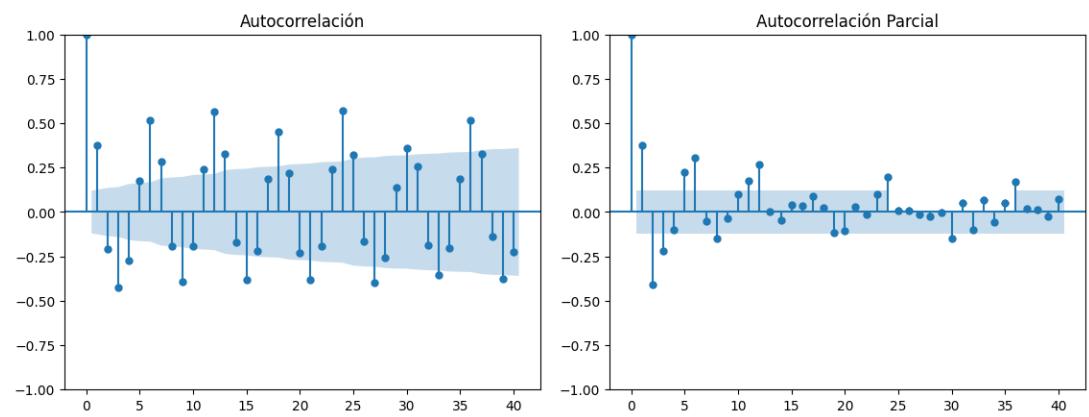
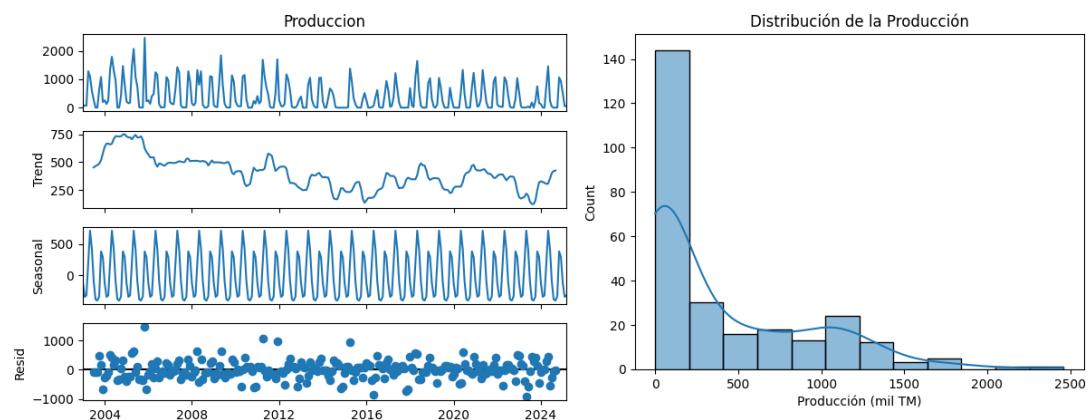
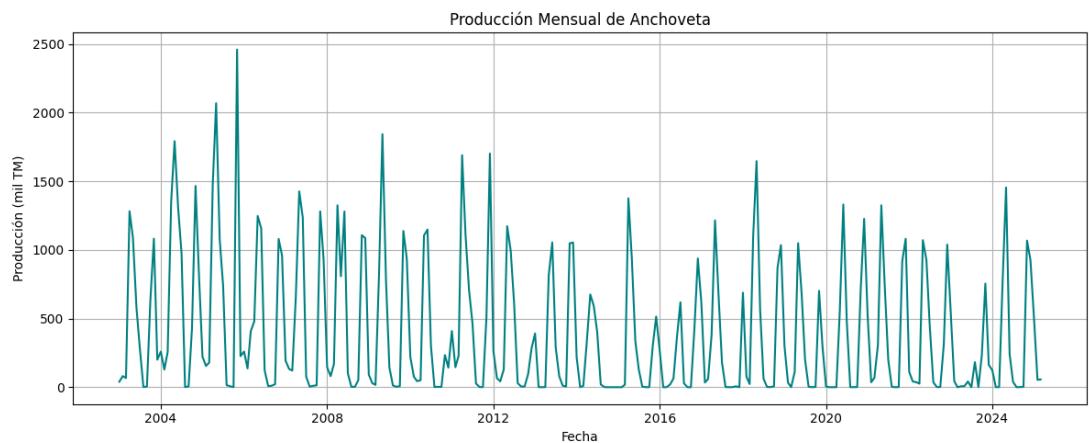
donde  $X_t$  representa variables exógenas (por ejemplo, índices climáticos como el SOI o las anomalías ONI), y  $\beta$  son sus coeficientes. Este modelo es especialmente útil para series temporales afectadas por factores externos, como en el caso de la producción pesquera influenciada por condiciones oceánicas.

## 2.3 Comparación de Modelos

En esta etapa, se procedió a cargar los datos de producción mensual de anchoveta dado que existen dos temporadas de pesca por año, lo cual introduce una componente estacional importante en la serie temporal esto es importante a la hora de elegir el modelo. Tras la carga de los datos, se realizó una visualización exploratoria para observar el comportamiento general de la producción a lo largo del tiempo, identificando patrones cíclicos y posibles anomalías.

Posteriormente, observamos los gráficos de la Función de Autocorrelación (ACF) y de Autocorrelación Parcial (PACF), los cuales sugirieron una estructura temporal compleja, con presencia de autocorrelación significativa a ciertos rezagos, compatible con la presencia de estacionalidad.

En la siguiente figura se presentan los gráficos de la Función de Autocorrelación (ACF) y la Función de Autocorrelación Parcial (PACF) para la serie de producción mensual de anchoveta. El gráfico de ACF muestra una autocorrelación significativa en múltiples rezagos, especialmente en los múltiplos de 12 (lags 12, 24, 36, etc.), lo cual evidencia una marcada estacionalidad anual en los datos. Además, la lenta disminución de la autocorrelación indica que la serie no es estacionaria en nivel, sugiriendo la necesidad de aplicar diferenciación. Por otro lado, el gráfico de PACF presenta un corte notable en el primer rezago y algunos valores significativos hasta el lag 6, lo que sugiere la presencia de un componente



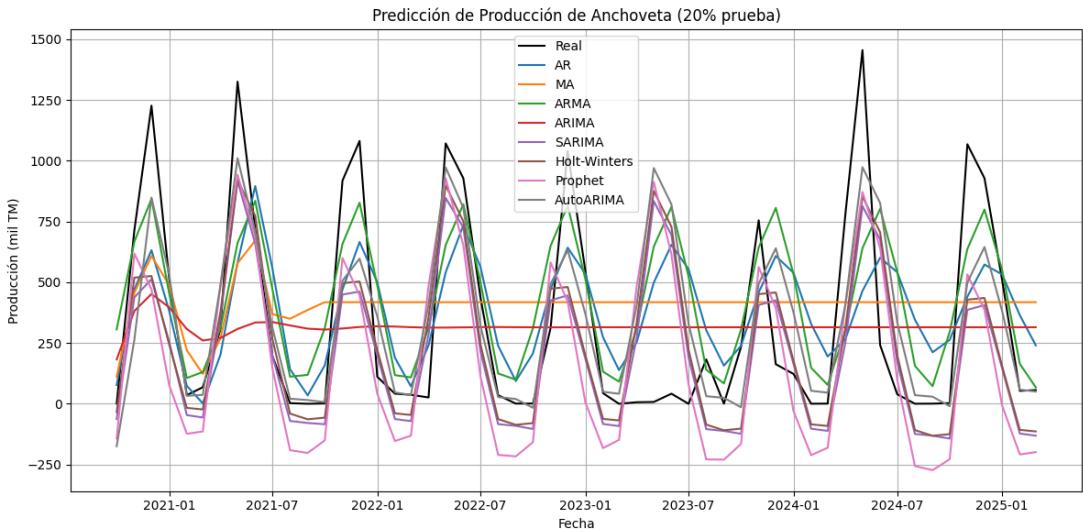


Table 1: Tabla de Métricas de Evaluación

Modelo	MSE	RMSE	MAE	MAPE
AutoARIMA	90 248.45	300.41	207.77	18 777.91
Holt-Winters	102 176.83	319.65	246.13	18 211.45
ARMA	102 766.54	320.57	243.15	35 159.86
SARIMA	107 476.23	327.84	255.56	18 978.05
AR	122 664.79	350.24	284.33	40 699.40
Prophet	126 817.30	356.11	302.02	22 979.96
MA	167 586.14	409.37	359.69	63 132.84
ARIMA	176 503.66	420.12	349.37	48 047.33

autorregresivo de orden bajo. En conjunto, estos patrones justifican el uso de modelos de tipo SARIMA con diferenciación tanto regular como estacional, considerando una periodicidad de 12 meses.

Para verificar la estacionariedad, condición fundamental para la aplicabilidad de varios modelos clásicos de series temporales, se llevó a cabo la prueba de Dickey-Fuller aumentada (ADF). Se obtuvo un estadístico ADF de -2.559 y un p-valor de 0.1017, lo que indica que no es estacionaria. Esta característica representa un desafío, ya que modelos como AR (autorregresivo), MA (media móvil) y ARMA (combinación de ambos) suponen estacionariedad en los datos y, además, no son capaces de modelar estacionalidad de forma explícita. Por ello, estos modelos se consideraron como referencia, pero no como candidatos principales para el pronóstico final. La serie fue dividida en conjuntos de entrenamiento (80%) y prueba (20%) para evaluar la capacidad predictiva de los modelos. Se ajustaron y compararon distintos enfoques, incluyendo AR, MA, ARMA, ARIMA, SARIMA, Holt-Winters, Prophet y AutoARIMA. Los modelos se evaluaron utilizando métricas comunes de error de pronóstico: el Error Cuadrático Medio (MSE), la Raíz del Error Cuadrático Medio (RMSE), el Error Absoluto Medio (MAE) y el Porcentaje de Error Absoluto Medio (MAPE).

Los resultados muestran que el modelo AutoARIMA obtuvo el mejor desempeño general, con un MSE de 90,248.45 y un MAPE de 18,777.91, superando a los demás modelos tanto en precisión como en eficiencia. El método de Holt-Winters también mostró un rendimiento competitivo, con un MSE ligeramente mayor, pero un MAPE menor (18,211.45), lo cual sugiere que su capacidad para capturar la estacionalidad es adecuada.

En contraste, modelos como MA y ARIMA presentaron errores significativamente más altos, especialmente en términos de MAPE, alcanzando valores por encima de 48,000 y 63,000 respectivamente, lo que indica una alta desviación relativa respecto a los valores reales. Prophet, aunque incorpora componentes

SARIMAX Results						
Dep. Variable:	y	No. Observations:	213			
Model:	SARIMAX(5, 1, 0)x(0, 1, [1, 2], 12)	Log Likelihood	-1462.033			
Date:	Mon, 16 Jun 2025	AIC	2940.066			
Time:	18:26:47	BIC	2966.452			
Sample:	01-01-2003 - 09-01-2020	HQIC	2950.744			
Covariance Type:	opg					
coef	std err	z	P> z	[0.025	0.975]	
ar.L1	-0.7038	0.067	-10.497	0.000	-0.835	-0.572
ar.L2	-0.6896	0.096	-7.176	0.000	-0.878	-0.501
ar.L3	-0.5411	0.099	-5.459	0.000	-0.735	-0.347
ar.L4	-0.4583	0.085	-5.410	0.000	-0.624	-0.292
ar.L5	-0.3915	0.071	-5.501	0.000	-0.531	-0.252
ma.S.L12	-0.9969	0.063	-15.871	0.000	-1.120	-0.874
ma.S.L24	0.2193	0.066	3.335	0.001	0.090	0.348
sigma2	1.228e+05	1.02e+04	11.980	0.000	1.03e+05	1.43e+05
Ljung-Box (L1) (Q):	0.59	Jarque-Bera (JB):	17.05			
Prob(Q):	0.44	Prob(JB):	0.00			
Heteroskedasticity (H):	1.01	Skew:	0.25			
Prob(H) (two-sided):	0.98	Kurtosis:	4.34			

estacionales de forma automática, también mostró errores elevados, lo que sugiere que su configuración predeterminada no se adaptó del todo bien a las características específicas de esta serie. Estos resultados refuerzan la importancia de modelar explícitamente la estacionalidad, especialmente en series como la producción pesquera, donde factores climáticos, ciclos biológicos y normativas de pesca pueden influir significativamente en los patrones observados.

El modelo SARIMAX ajustado presenta una estructura SARIMAX(5, 1, 0)x(0, 1, [1, 2], 12), lo cual indica la presencia de cinco términos autorregresivos de corto plazo, una diferenciación regular y una componente estacional anual con diferenciación y dos términos de media móvil estacional en los rezagos 12 y 24. Todos los coeficientes estimados son estadísticamente significativos ( $p < 0.05$ ), y el modelo logra capturar la dinámica estacional de la producción de anchoveta. El test de Ljung-Box aplicado a los residuos muestra un valor  $p$  de 0.44, lo que sugiere ausencia de autocorrelación residual. Sin embargo, la prueba de Jarque-Bera indica que los residuos no siguen una distribución normal, aunque esto no compromete gravemente la capacidad predictiva del modelo. En general, el modelo demuestra un buen ajuste y es adecuado para generar pronósticos a corto plazo.

## 2.4 Modelo Sarimax

En esta sección se desarrolló un modelo SARIMAX incorporando variables exógenas con el objetivo de mejorar la capacidad predictiva respecto a un modelo SARIMA puro. Para ello, se integraron al modelo tres variables climáticas de interés: el índice SOI (Southern Oscillation Index) y los valores de anomalía de temperatura superficial del mar correspondientes a las regiones Niño 1+2 (ANOM12) y Niño 3.4 (ANOM34), obtenidas del conjunto de datos ONI. Estas variables fueron seleccionadas debido a su conocida influencia sobre las condiciones oceánicas del Pacífico, que a su vez impactan en la biomasa y distribución de la anchoveta peruana. Se llevó a cabo una comparación sistemática de modelos SARIMAX considerando distintas combinaciones de estas variables exógenas. Los resultados evidencian que la inclusión de variables exógenas no garantiza automáticamente una mejora sustancial del modelo; por ejemplo, al incluir únicamente el SOI o solo ANOM12, los errores cuadráticos medios (MSE) se mantuvieron por encima de los 100,000, con valores de RMSE superiores a 317 y errores porcentuales medios (MAPE) extremadamente elevados, cercanos o superiores al 17,000%. Sin embargo, al combinar las variables SOI y ANOM12 se obtuvo el mejor desempeño predictivo entre todos los modelos evaluados, logrando reducir el RMSE a 304.47, el MAE a 225.80 y el MAPE a aproximadamente 15,947%, lo que

Table 2: Model Comparison for SARIMAX with Different Exogenous Variables

Model	MSE	RMSE	MAE	MAPE
SOI	100 571.05	317.129	242.559	18 098.73
ANOM12	103 627.87	321.913	251.479	17 958.88
SOI+ANOM12*	92 702.90	304.472	225.807	15 947.16
SOI+ANOM12+ANOM34	99 345.74	315.192	239.915	16 940.19

\* Best model based on RMSE.

sugiere una contribución complementaria de ambas variables climáticas en la explicación de la variabilidad de la producción mensual de anchoveta. En contraste, la adición de ANOM34 al modelo (es decir, el modelo con las tres variables) no mejoró los resultados, ya que las métricas de error se incrementaron nuevamente, lo cual puede atribuirse a redundancia informativa o a la incorporación de ruido adicional. Estos hallazgos resaltan la importancia de una selección cuidadosa de variables exógenas en la modelación de series temporales multivariadas, así como la necesidad de evaluar combinaciones específicas en lugar de asumir que más variables necesariamente conducen a un mejor ajuste. En resumen, el modelo SARIMAX con las variables SOI y ANOM12 se posiciona como la mejor alternativa dentro del conjunto probado, destacando el rol relevante de estos dos indicadores climáticos en la dinámica de la pesca de anchoveta.

Ahora procederemos a buscar los mejores parámetros mediante grid search que busca sistemáticamente la mejor combinación de valores de hiperparámetros evaluando todas las combinaciones posibles dentro de una cuadrícula definida. Es una búsqueda exhaustiva, lo que significa que prueba todas las configuraciones posibles para encontrar la óptima en función de una métrica de rendimiento elegida. En nuestro caso son  $[p, d, q, P, D, Q]$  6 parámetros en total si le asignamos un rango de 5 valores tendríamos una combinación de 5 a la 6 multiplicado por 4 tipos de modelo se tendría que probar 62500 modelos esto resultaría muy costoso en términos de la capacidad de computo. Para el estudio se tomo algunos parametros fijos y otros con pocos valores de rango tomando como base el el modelo anterior. Asignamos como parámetros los siguientes valores  $p = [4, 5, 6]$ ,  $d = [1]$ ,  $q = [0, 1]$ ,  $P = [0, 1]$ ,  $D = [1]$ ,  $Q = [1, 2]$ ,  $s = 12$  en este caso tenemos 24 combinaciones por 4 tipos seria un total de 96 modelos a probar

Table 3: Comparación de modelos SARIMAX con diferentes combinaciones

Exógena	Orden	Orden estacional	AIC	MSE	RMSE	MAE	MAPE
ANOM12	(5,1,1)	(0,1,2,12)	2483.96	87900.54	296.48	216.33	12620.93
	(4,1,1)	(0,1,2,12)	2483.41	89861.65	299.77	219.94	12754.28
	(5,1,1)	(1,1,1,12)	2624.63	91637.18	302.72	225.79	14696.45
	(6,1,1)	(0,1,2,12)	2483.23	94470.99	307.36	227.48	12490.90
	(4,1,1)	(1,1,1,12)	2638.28	92774.76	304.59	231.21	14801.84
	(5,1,1)	(1,1,2,12)	2485.28	99460.52	315.37	236.11	15824.75
SOI	(5,1,1)	(0,1,2,12)	2479.91	81672.80	285.78	203.18	12506.38
	(4,1,1)	(0,1,2,12)	2479.56	82863.53	287.86	203.24	11925.01
	(5,1,1)	(1,1,2,12)	2480.40	81620.10	285.69	204.29	13073.26
	(5,1,1)	(1,1,1,12)	2621.25	81935.09	286.24	205.82	13554.66
	(6,1,1)	(0,1,2,12)	2479.19	83874.37	289.61	205.98	10983.41
	(4,1,1)	(1,1,2,12)	2479.36	83963.13	289.76	208.01	13202.24
SOI+ANOM12	(5,1,1)	(1,1,2,12)	2482.29	82772.41	287.70	203.74	13598.95
	(4,1,1)	(0,1,2,12)	2481.17	84554.89	290.78	204.36	12977.08
	(5,1,1)	(0,1,2,12)	2481.59	81627.94	285.71	204.93	13374.15
	(5,1,1)	(1,1,1,12)	2623.39	82099.12	286.53	205.82	13757.44
	(6,1,1)	(0,1,2,12)	2481.12	87290.04	295.45	207.15	11838.06
	(4,1,1)	(1,1,2,12)	2481.07	84785.64	291.18	207.34	13787.86
SOI+ANOM12+ANOM34	(4,1,1)	(0,1,2,12)	2483.83	85044.84	291.62	205.66	13769.78
	(5,1,1)	(1,1,1,12)	2626.02	81005.70	284.62	205.75	12607.76
	(4,1,1)	(1,1,1,12)	2641.54	85599.67	292.57	206.76	12487.48
	(5,1,1)	(0,1,2,12)	2485.87	86791.19	294.60	208.17	17444.77
	(5,1,1)	(1,1,2,12)	2485.93	85796.18	292.91	208.52	16201.41
	(4,1,1)	(1,1,2,12)	2484.86	87690.93	296.13	208.96	14788.96

las mejores combinaciones resultan:

Table 4: mejores modelos

Model	Order	Seasonal Order	AIC	MSE	RMSE	MAE	MAPE
ANOM12	(5, 1, 1)	(0, 1, 2, 12)	2483.96	87900.54	296.48	216.33	12620.93
SOI	(5, 1, 1)	(0, 1, 2, 12)	2479.91	81672.80	285.78	203.18	12506.38
SOI+ANOM12	(5, 1, 1)	(1, 1, 2, 12)	2482.29	82772.41	287.70	203.74	13598.95
SOI+ANOM12+ANOM34	(4, 1, 1)	(0, 1, 2, 12)	2483.83	85044.84	291.62	205.66	13769.78

### 3 Resultados

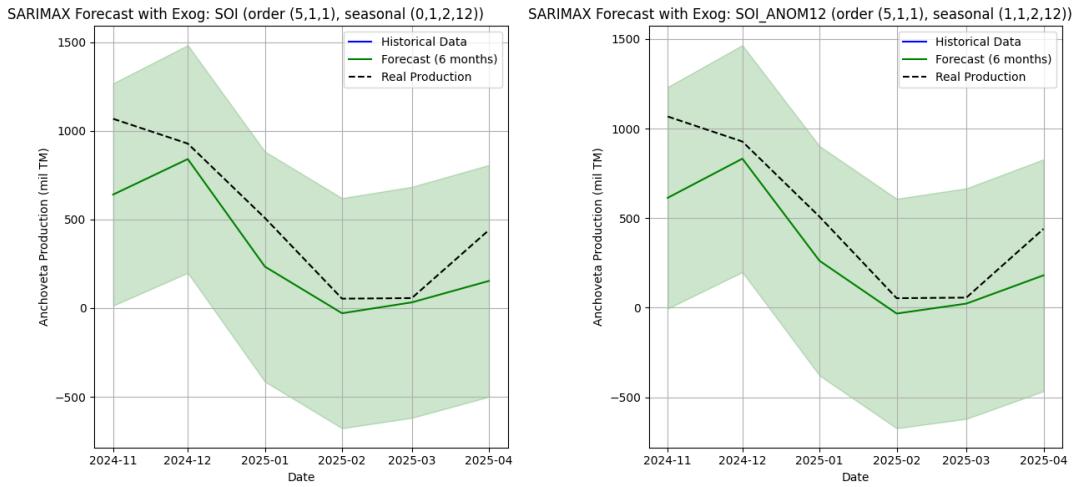
#### 3.1 Pronostico Futuro

Con el modelo SARIMAX ajustado previamente, se realizó un pronóstico de la producción mensual de anchoveta para los próximos seis meses (noviembre 2024 a abril de 2025), incorporando las variables exógenas climáticas que mostraron mejor desempeño en la etapa de evaluación: el índice SOI y la anomalía de temperatura superficial ANOM12. Los valores proyectados reflejan tanto la estacionalidad característica de la serie como los posibles efectos de las condiciones climáticas recientes. Del resultado anterior tomamos los 2 mejores modelos con los MAE mas bajos SOI [(5,1,1),(0,1,2,12)] y SOI+ANOM12 [(5,1,1),(1,1,2,12)]. Se entrenaron dos modelos SARIMA utilizando la serie completa de producción mensual de anchoveta, incorporando variables exógenas climáticas. Obteniendo resultados similares en términos de precisión. El modelo con SOI obtuvo un RMSE de 243.24 y un MAPE de 60.94%, mientras que el modelo con SOI y ANOM12 presentó un RMSE ligeramente menor (242.07) y un MAE de 195.74, aunque con un MAPE más alto (63.42%). Estos resultados sugieren que, si bien la inclusión de ANOM12 mejora ligeramente el ajuste absoluto, el modelo con solo SOI presenta un mejor desempeño relativo en términos de error porcentual. En conjunto, estas estimaciones permiten anticipar escenarios productivos y tomar decisiones estratégicas en la gestión pesquera, como el establecimiento de cuotas, la planificación logística y la evaluación de impactos ambientales. No obstante, es importante señalar que la incertidumbre del modelo permanece elevada, por lo que estas predicciones deben interpretarse con cautela y preferentemente complementarse con información de monitoreo oceanográfico y biológico en tiempo real.

Table 5: Pronóstico a 6 meses del modelo SARIMA con variables exógenas

Modelo	Fecha	Pronóstico	IC Inferior	IC Superior	Valor Real
6*SOI	2024-11-01	640.46	13.65	1267.27	1067.65
	2024-12-01	840.58	198.31	1482.85	927.85
	2025-01-01	233.98	-415.03	882.99	508.20
	2025-02-01	-28.89	-677.90	620.12	53.21
	2025-03-01	32.35	-619.10	683.80	56.53
	2025-04-01	153.27	-500.49	807.03	440.27
		MSE: 59,167.52	RMSE: 243.24	MAE: 197.00	MAPE: 60.94%
6*SOI + ANOM12	2024-11-01	613.72	-5.00	1232.44	1067.65
	2024-12-01	832.19	198.45	1465.94	927.85
	2025-01-01	261.94	-378.88	902.75	508.20
	2025-02-01	-32.48	-673.31	608.34	53.21
	2025-03-01	23.03	-620.59	666.64	56.53
	2025-04-01	180.92	-466.35	828.19	440.27
		MSE: 58,597.88	RMSE: 242.07	MAE: 195.74	MAPE: 63.42%

La Figura presenta una comparación visual entre las predicciones realizadas por dos modelos SARIMAX entrenados con distintas combinaciones de variables exógenas y su capacidad para anticipar la producción mensual de anchoveta en Perú durante un horizonte de seis meses. El gráfico de la izquierda corresponde al modelo SARIMAX con la variable exógena SOI (índice de oscilación del sur), utilizando un orden (5,1,1) y un componente estacional (0,1,2,12). Por otro lado, el gráfico de la derecha muestra los resultados del modelo que incorpora tanto SOI como ANOM12 (anomalía de temperatura superficial del mar en la región 1+2), con el mismo orden no estacional (5,1,1), pero un orden estacional diferente: (1,1,2,12). En ambos casos, las líneas verdes representan el pronóstico del modelo, mientras que las



áreas sombreadas corresponden a los intervalos de confianza del 95%. La línea azul muestra los datos históricos más recientes usados para el entrenamiento, y la línea negra punteada representa la producción real observada en el periodo de prueba (noviembre 2024 a abril 2025).

Se observa que ambos modelos siguen una trayectoria similar en sus predicciones, anticipando correctamente la fuerte caída en la producción a partir de enero de 2025. No obstante, ambos tienden a subestimar la magnitud real de la producción en los meses extremos (noviembre y abril), lo cual se refleja en que la línea negra se posiciona por encima de la línea verde en dichos puntos. El modelo que utiliza solo SOI muestra intervalos de confianza ligeramente más amplios en los meses de menor producción, lo cual indica una mayor incertidumbre ante escenarios extremos. Por su parte, el modelo que incluye tanto SOI como ANOM12 presenta una banda de confianza más estrecha en febrero y marzo, lo cual sugiere una mayor precisión estimada, aunque en la práctica las predicciones siguen estando por debajo del valor real.

En conjunto, ambos modelos son capaces de capturar la estacionalidad y la tendencia general de la serie, especialmente la caída típica de producción en los primeros meses del año. Sin embargo, aún existe una brecha considerable entre el pronóstico y la realidad en ciertos meses, lo cual indica que, si bien el uso de variables climáticas como SOI y ANOM12 aporta valor predictivo, podrían ser necesarias variables adicionales o ajustes finos al modelo para mejorar la capacidad de predicción en períodos críticos de alta o baja producción.

## 4 Conclusiones

El modelo SARIMAX implementado permitió capturar tanto la estacionalidad estructural del ciclo de pesca como el efecto de variabilidad climática. Aunque la correlación lineal entre los índices ONI/SOI y la producción fue débil, su inclusión como variables exógenas mejoró la precisión predictiva respecto a modelos tradicionales. Este resultado coincide con Oliveros-Ramos Shin (2023), quienes resaltan el papel creciente del clima en la disminución proyectada de la biomasa de anchoveta en el largo plazo. Complementariamente, Arias Schreiber et al. (2011) enfatizan cómo, en escenarios pasados, la capacidad adaptativa del sector mitigó parcialmente dichos impactos. Se concluye que la integración de modelos predictivos con variables climáticas es una herramienta clave para la gestión preventiva y sostenible de la pesquería. Entre las combinaciones evaluadas, el modelo SARIMAX que integró SOI + ONI 1+2 presentó el mejor desempeño predictivo (RMSE 242, MAE 196), superando al uso individual de cualquier índice. Este hallazgo coincide con estudios como el de Oliveros-Ramos, quienes subrayan la necesidad de considerar múltiples dimensiones del ENSO para anticipar impactos en biomasa. En contraste, Arias Schreiber enfatiza más la respuesta institucional que la precisión del modelo. Ambos enfoques pueden complementarse al diseñar alertas tempranas que combinen monitoreo climático y acciones operativas de pesca. Las correlaciones observadas fueron bajas (SOI: 0.06, ONI 1+2: -0.13, ONI 3.4: -0.092), lo

que indica una influencia climática no lineal o rezagada, posiblemente modulada por otros factores como esfuerzo pesquero y políticas de veda. Esta interpretación es coherente con la evidencia de Arias Schreiber, que señala cómo, pese a eventos extremos, la flota ajustó rutas y estrategias para mantener capturas. En cambio, Oliveros-Ramos anticipa que el cambio climático futuro superará la capacidad adaptativa actual, lo cual complementa la necesidad de mejorar los modelos integrando desfases y escenarios futuros. El análisis de variables exógenas confirmó que el SOI y el ONI 1+2 aportan información complementaria al modelo, mientras que el ONI 3.4 no mejora significativamente el ajuste .Esto refuerza la tesis de que la combinación atmósfera-océano debe considerarse simultáneamente, como también lo concluye Oliveros-Ramos. En términos operativos, Arias Schreiber propone que este tipo de evidencia puede guiar decisiones sobre distribución de esfuerzo y diseño de vedas en años con condiciones anómalas.



## References

- Barber, R. T., & Chavez, F. P. (1983). Biological consequences of el niño. *Science*, 222(4629), 1203–1210. <https://doi.org/10.1126/science.222.4629.1203>
- Chavez, F. P., Ryan, J., Lluch-Cota, S. E., & Niñueno C., M. (2003). From anchovies to sardines and back: Multidecadal change in the pacific ocean. *Science*, 299(5604), 217–221. <https://doi.org/10.1126/science.1075880>
- Bertrand, A., Segura, M., Gutiérrez, M., & Vásquez, L. (2004). From small-scale habitat loopholes to decadal cycles: A habitat-based hypothesis explaining fluctuation in pelagic fish populations off peru. *Fish and Fisheries*, 5(4), 296–316. <https://doi.org/10.1111/j.1467-2679.2004.00165.x>
- Niñueno, M., & Bouchon, M. (2004). Impact of el niño events on pelagic fisheries in peruvian waters. *Deep Sea Research Part II: Topical Studies in Oceanography*, 51(6–9), 563–574. <https://doi.org/10.1016/j.dsr2.2004.03.001>
- Bakun, A., & Weeks, S. J. (2008). The marine ecosystem off peru: What are the secrets of its fishery productivity and what might its future hold? *Progress in Oceanography*, 79(2–4), 290–299. <https://doi.org/10.1016/j.pocean.2008.10.027>
- Bertrand, A., Gerlotto, F., Bertrand, S., Gutiérrez, M., Alza, L., Chipollini, A., Díaz, E., Espinoza, P., Ledesma, J., Quesquén, R., Peraltilla, S., & Chavez, F. (2008). Schooling behaviour and environmental forcing in relation to anchoveta distribution: An analysis across multiple spatial scales. *Progress in Oceanography*, 79(2–4), 264–277. <https://doi.org/10.1016/j.pocean.2008.10.018>
- Arias Schreiber, M. (2012). The evolution of legal instruments and the sustainability of the peruvian anchovy fishery. *Marine Policy*, 36(1), 78–89. <https://doi.org/10.1016/j.marpol.2011.03.010>
- Sherman, K. (2015). Sustaining the world's large marine ecosystems. *ICES Journal of Marine Science*, 72(9), 2521–2531. <https://doi.org/10.1093/icesjms/fsv136>
- Peruano, E. (2016, April). La acuicultura representará el 15% del pbi pesquero nacional. <https://www.elperuano.pe/noticia/38423-la-acuicultura-representara-el15-del-pbi-pesquero-nacional>
- Raman, R. K., Mohanty, S. K., Bhatta, K. S., Karna, S. K., Sahoo, A. K., Mohanty, B. P., & Das, B. K. (2018). Time series forecasting model for fisheries in chilika lagoon (a ramsar site, 1981), odisha, india: A case study. *Wetlands Ecology and Management*, 26(4), 677–687. <https://doi.org/10.1007/s11273-018-9600-4>
- Timmermann, A., An, S.-I., Kug, J.-S., Jin, F.-F., Cai, W., Capotondi, A., Cobb, K. M., Lengaigne, M., McPhaden, M. J., Stuecker, M. F., Stein, K., Wittenberg, A. T., Yun, K.-S., Bayr, T., Chen, H.-C., Chikamoto, Y., Dewitte, B., Dommgenget, D., Grothe, P., ... Zhang, X. (2018). El niño–southern oscillation complexity. *Nature*, 559(7715), 535–545. <https://doi.org/10.1038/s41586-018-0252-6>
- Bouchon, G., C.Peña. (2019). Cambios en la distribución de la anchoveta durante eventos el niño extraordinarios (1982-83 y 1997-98) y el niño costero 2017. <https://repositorio.igp.gob.pe/items/0b9afbeb-cce9-4da2-8d76-2ed222dce90e>
- Yadav. (2021). Forecasting quarterly landings of total fish and major pelagic fishes and modelling the impacts of climate change on bombay duck. <https://nopr.niscpr.res.in/bitstream/123456789/57950/1/IJMS%2050%287%29%20%28557-565%29.pdf>
- Oliveros-Ramos, R., & Shin, Y.-J. (2023a). Future climate change impacts on anchoveta (*engraulis ringens*) in the northern peru current ecosystem. <https://doi.org/10.1101/2023.02.14.528548>
- Oliveros-Ramos, R., & Shin, Y.-J. (2023b). Future climate change impacts on anchoveta (*engraulis ringens*) in the northern peru current ecosystem. <https://doi.org/10.1101/2023.02.14.528548>
- BCRP. (2024, March). Notas de estudios del bcrp no. 21 – 21 de marzo de 2024. <https://www.bcrp.gob.pe/docs/Publicaciones/Notas-Estudios/2024/nota-de-estudios-21-2024.pdf>
- FAO. (2024, July). *El estado mundial de la pesca y la acuicultura 2024*. Food; Agriculture Organization. <https://doi.org/10.4060/cd0683es>
- BCRP. (2025, February). Pesca marítima - consumo industrial - anchoveta. <https://estadisticas.bcrp.gob.pe/estadisticas/series/mensuales/resultados/PN01848AM/html>
- FAO. (2025). Especies acuáticas - *en graulis ringens*. <https://www.fao.org/fishery/en/aqspecies/2917/en>

- FishBase. (2025). Engraulis ringens, anchoveta : Fisheries. <https://www.fishbase.se/summary/SpeciesSummary.php?ID=4&AT=Anchovy>
- NOAA. (2025a, May). Pacific sea surface temperatures (sst). <https://www.ncei.noaa.gov/access/monitoring/enso/sst>
- NOAA. (2025b, May). Southern oscillation index (soi). <https://www.ncei.noaa.gov/access/monitoring/enso/soi>
- RAE. (2025, April). Anchoa — definición — diccionario de la lengua española — rae - asale. <https://dle.rae.es/anchoa#2XZOKks>

